

# 1. Show that the sliced score matching (SSM) loss can also be written as

$$L_{SSM} = \mathbb{E}_{x \sim p(x)} \mathbb{E}_{v \sim p(v)} [\|v^T S(x; \theta)\|^2 + 2v^T \nabla_x (v^T S(x; \theta))]$$

1. 目標是最小化模型預測的對數機率密度梯度 ( 分數 )  $S(x; \theta)$  與真實數據分佈  $p(x)$  的分數  $\nabla_x \log p(x)$  之間的差距。目標函數為：

$$J(\theta) = \frac{1}{2} \mathbb{E}_{x \sim p(x)} [\|S(x; \theta) - \nabla_x \log p(x)\|^2]$$

因為  $\nabla_x \log p(x)$  未知所以無法直接計算。

2. 透過將分數向量投影到隨機的單位向量  $v$  上，將高維度的向量匹配問題轉化為一維標量的匹配問題，從而簡化計算。SSM 的目標函數定義為：

$$L_{SSM\_original} = \frac{1}{2} \mathbb{E}_{v \sim p(v)} \mathbb{E}_{x \sim p(x)} [(v^T S(x; \theta) - v^T \nabla_x \log p(x))^2]$$

3. 展開平方項：

$$(v^T S - v^T \nabla_x \log p)^2 = (v^T S)^2 - 2(v^T S)(v^T \nabla_x \log p) + (v^T \nabla_x \log p)^2$$

對  $x$  取期望後，目標函數變為 ( 忽略常數 和對  $v$  的期望 )：

$$\mathbb{E}_x [(v^T S)^2] - 2\mathbb{E}_x [(v^T S)(v^T \nabla_x \log p)] + \mathbb{E}_x [(v^T \nabla_x \log p)^2]$$

- 第三項  $\mathbb{E}_x [(v^T \nabla_x \log p)^2]$  是數據真實分佈的 Fisher divergence，它與模型參數  $\theta$  無關，因此可忽略。
- 第一項  $(v^T S)^2$  是一個標量的平方，等價於其 L2 範數的平方  $\|v^T S\|^2$ 。

所以需要再處理：

$$L(\theta) \propto \mathbb{E}_x [\|v^T S(x; \theta)\|^2] - 2\mathbb{E}_x [(v^T S(x; \theta))(v^T \nabla_x \log p(x))]$$

4. 使用 Integration by Parts

因為  $h(x)$  和機率密度  $p(x)$  ( 在邊界處  $p(x)h(x) = 0$  )，有：

$$\mathbb{E}_{p(x)} [\nabla_x^T h(x)] = -\mathbb{E}_{p(x)} [h(x)^T \nabla_x \log p(x)]$$

讓  $h(x) = (v^T S(x; \theta))v$ 。因為  $h(x)$  是一個向量函數。所以  
 $h(x)^T \nabla_x \log p(x) = ((v^T S)v)^T \nabla_x \log p(x) = (v^T S)(v^T \nabla_x \log p(x))$ 。

因此我們可以得到：

$$\mathbb{E}_x [(v^T S)(v^T \nabla_x \log p)] = -\mathbb{E}_x [\nabla_x^T h(x)] = -\mathbb{E}_x [\nabla_x^T ((v^T S)v)]$$

因為  $v$  是一個常數向量， $\nabla_x^T ((v^T S)v) = v^T \nabla_x (v^T S)$ 。所以，

$$\mathbb{E}_x [(v^T S)(v^T \nabla_x \log p)] = -\mathbb{E}_x [v^T \nabla_x (v^T S(x; \theta))]$$

5. 將結果代回  $L(\theta)$  :

$$L(\theta) \propto \mathbb{E}_x[\|v^T S(x; \theta)\|^2] - 2(-\mathbb{E}_x[v^T \nabla_x(v^T S(x; \theta))])$$

$$L(\theta) \propto \mathbb{E}_x[\|v^T S(x; \theta)\|^2 + 2v^T \nabla_x(v^T S(x; \theta))]$$

最後，將對隨機向量  $v$  的期望加回來，就得到了最終的表達式：

$$L_{SSM} = \mathbb{E}_{v \sim p(v)} \mathbb{E}_{x \sim p(x)} [\|v^T S(x; \theta)\|^2 + 2v^T \nabla_x(v^T S(x; \theta))]$$

## 2. Briefly explain SDE

(Stochastic Differential Equation, SDE) 是一種特殊的微分方程，它的方程中包含至少一個隨機過程\*項（通常是白噪音的積分）。因此，SDE 的解本身也是一個隨機過程，而不像普通微分方程 (ODE) 的解是一個確定的函數。

一般形式：

一個 SDE 通常可以寫成如下形式：

$$dX_t = f(X_t, t)dt + g(X_t, t)dW_t$$

這裡的各項代表：

- $X_t$ ：表示一個隨機過程在時間  $t$  的狀態。
- $dX_t$ ：表示狀態  $X_t$  在一個極小的時間  $dt$  內的變化量。
- $f(X_t, t)dt$ ：稱為**Drift Term**。它描述了  $X_t$  隨時間演變的確定性、可預測的平均趨勢。
- $g(X_t, t)dW_t$ ：稱為**Diffusion Term**。它描述了  $X_t$  演變過程中的隨機波動或不確定性。
  - $g(X_t, t)$  決定了隨機波動的幅度。
  - $dW_t$  是一個維納過程（或布朗運動）的無窮小增量，可以理解為一個服從正態分佈的隨機噪音項。

SDE 的目標是將一個連續變化的過程分解為兩部分：一部分是**確定性的平均行為**（漂移），另一部分是**不可預測的隨機擾動**（擴散）。

## 3. Unanswered Questions

在 SSM 中，會將 score 投影到一個隨機向量  $v$  上。 $p(v)$  除了球面均勻分佈，能否使用其他分佈？不同的選擇會有顯著影響模型的訓練效率和性能？