

# Written assignment

## 1. Week 1 Question

Q. 梯度下降可能卡在 local minima 非 Global minima，在高維度時 saddle point 和 plateau 導致學習緩慢

A. 現代研究指出，在高維空間 (High-dimensional space，即參數非常多的深度神經網路) 中，問題通常不是 Local Minima，而是 鞍點 (Saddle Points)。而 Saddle point 問題則可以使用帶有 動量 (Momentum) 的優化器 (如 SGD with Momentum 或 Adam)，利用過去的慣性衝過平坦的鞍點區域。

相關文獻：Dauphin, Y. N., et al. (2014). "Identifying and attacking the saddle point problem in high-dimensional non-convex optimization". NeurIPS.

Q. 如何找到適合的 lr?

A. 在訓練開始前，先跑一個極短的 epoch。讓 LR 從非常小 (如 1e-7) 指數增長到非常大 (如 10)

相關文獻：Smith, L. N. (2017). "Cyclical Learning Rates for Training Neural Networks". IEEE WACV.

## 2. Week 2 Question

Q. 對於二元分類問題，loss function 好像更常使用 Cross-Entropy，MSE 在 (one-hot encoder)下 假如使用 sigmoid： $\sigma(z)$ 的導數是 $\sigma(z)(1-\sigma(z))$  實為 1 預測輸出非常錯誤 假設為 0.01 時 就會導致梯度變得非常小，幾乎為零 因為 MSE 假設預測目標是連續的，且誤差服從高斯分佈。但分類問題是離散的，One-hot encoder 雖然轉化為數值向量，但不知道理論上這樣是不是合理的？

A. 雖然 One-hot encoding 把離散變量變成了向量，但它仍然代表機率分佈，而非連續數值。因此，使用 MSE 在理論上是「模型假設與數據本質不符」，在實作上則會導致學習停滯。

相關文獻：Golik, P., et al. (2013). "Cross-entropy vs. squared error training: a theoretical and experimental comparison". Interspeech.

Q. Approximation Theory 提到可以用  $p$  個神經元來近似  $x^2 p - 1$ ，如

果要近似更高次的多項式，是否需要更多神經元的網路，和網路深度是否效果不同？

A. 取決於要增加深度還寬度，如果是深度：若第一層做  $X^2$ ，第二層做  $((X^2)^2 = X^4)$  第  $p$  層就能達到  $X^{2p}$ 。只需  $O(p)$  個神經元。如果是淺層，根據 Universal Approximation Theorem，一個只有單隱藏層的淺層網路確實可以近似任何函數。但是為了近似像  $x^{2p-1}$  這樣的高階多項式或高頻震盪函數，淺層網路需要指數級 ( $2^p$ ) 的神經元數量。

### 3. Week 3 Question

Q. 在網絡架構中使用奇函數或週期函數（如  $\sin, \cos, \sin, \cos$ ）是否有幫助？

A. 例如 Tanh 就是奇函數 ( $f(-x) = -f(x)$ )。它的優點是 Zero-centered (以零為中心)。這意味著輸出的期望值接近 0，這對於下一層的梯度傳播非常有利，比起 Sigmoid (輸出恆正) 能收斂得更快。

相關文獻：Sitzmann, V., et al. (2020). "Implicit Neural Representations with Periodic Activation Functions" (SIREN).

NeurIPS

Q. 對於  $p$  很大的  $X^P$ ，神經元數量和網路深度是否會有訓練困難？

A. 是，會導致極大的訓練困難。

### 4. Week 4 Question

Q. 為何 Logistic Regression (LR) 不使用最小平方法 (MSE)？如果使用會怎樣？

A. 雖然在數學上可以硬把 MSE 用在 Logistic Regression 上，但在實務上幾乎沒人這樣做，主要原因有兩點：非凸性 (Non-Convexity) 與 梯度消失 (Vanishing Gradient)。

Q. Newton's Method vs. Gradient Descent：何時使用哪一種？

A. 在實務上 (如 Scikit-Learn 的 Logistic Regression)，會用 L-BFGS。這是一種「擬牛頓法」(Quasi-Newton)。它不真正計算 Hessian 矩陣，而是通過歷次的梯度變化來「估計」Hessian 矩陣。這結合了 Gradient Descent 的低成本與 Newton's Method 的快收斂，是中型數據集的首選。

### 5. Week 5 Question

Q. GDA 是否比 Logistic Model 更強大或更嚴格？

A. GDA 確實比較「嚴格」(Stricter)，依賴更強的假設

- Q. 既然更嚴格，訓練效果一定會更好嗎  
A. 不一定。這取決於數據是否真的符合 GDA 的假設

相關文獻：Ng, A. Y., & Jordan, M. I. (2001). "On Discriminative vs. Generative Classifiers: A comparison of logistic regression and naive Bayes". NIPS.

## 6. Week 6 Question

- Q. 在偶函數的例子中，即使神經網路  $N$  使用了無限可微的激活函數  $\tanh$ ，建構出的  $u(x)=N(|X|)$ ，但在  $x=0$  處不可微，這樣 feedforward fully-connected neural network 的 regularity 還會和其他激活函數相同嗎？  
A. 不會。整個模型  $u(x)$  的正則性會被破壞，它不再是  $C^\infty$  (無限可微)，在  $x=0$  處會降級為  $C^0$  (僅連續但不可微)。

## 7. Week 7 Question

- Q. 在 DSM 中，加入的雜訊強度  $\sigma$  是否會影響模型的學習效果？如果雜訊太小或太大，會有啥效果？  
A.  $\sigma$  小 → 只有地圖上的道路有路標，野外沒有。一旦迷路（隨機初始化）就回不來了。 $\sigma$  大 → 整個地球都被標記成「往地心走」。你能找到地球，但找不到紐約市（細節丟失）。多尺度  $\sigma$  (Diffusion) → 先用衛星導航到城市，再用街道圖導航到門牌。

## 8. Week 8 Question

- Q. 在 SSM 中，會將 SCORE 投影到一個隨機向量  $V$  上， $p(V)$  除了球面均勻分布，能否使用其他分布？  
A. 可以，而且選擇不同的分佈確實會影響訓練的「穩定性」，但不會改變「理論上的最佳解」。

## 9. Week 10 Question

- Q. 在推倒 SDE 對應 ODE 時，如何確保解的唯一性和穩定性？  
A. 要確保 SDE 和 ODE 描述的是同一個機率分佈演化過程需要透過 Fokker-Planck 方程的等價性和 Trajectory Uniqueness，穩定性則靠神經網路的平滑設計 以及 先進的數值求解器 (DPM-Solver) 來克服剛性問題
- 相關文獻：Song, Y., et al. (2021). "Score-Based Generative Modeling through Stochastic Differential Equations". ICLR. (這篇論文的 Appendix D)  
Gyöngy, I. (1986). "Mimicking the one-dimensional marginal distributions of processes having an Itô differential".

Probability Theory and Related Fields.

## ● Toy model/Solvable Model Problem in your final project

### First Step of an AI Physicist: Rediscovering

#### Damped Dynamics from Data

##### 1. 前言：20 年後的願景

在我的 Final Project 構想中，預測 20 年後的 AI 將演化為「The Autonomous Scientific Discoverer」。屆時的 AI 不再僅僅是執行人類指令的計算工具，而是能夠直接觀察極端複雜的自然現象（例如：受控核融合中的電漿湍流、極端氣候的混沌系統），並在沒有人類預設方程式的情況下，自主推導出背後的物理定律與數學模型。

為了實現這個願景，必須從最基礎的物理單元開始驗證。如果 AI 無法理解簡單的機械震盪，它就不可能理解複雜的量子力學。因此，先設計一個可行的「簡化模型問題」，作為通往該能力的第一步。

##### 2. 設計思路

為了模擬 AI 「觀察現象並發現規律」的過程，我選擇了經典物理學中的「阻尼簡諧運動 Damped Harmonic Oscillator」作為本次的簡化模型。為什麼選擇這個模型？

單純的線性回歸過於簡單，無法體現物理世界的複雜性。而阻尼震盪系統包含了兩個動力學系統的核心特徵：

週期性 (Periodicity)：代表系統的震盪與波動特性。

能量耗散 (Dissipation)：振幅隨時間呈指數衰減，代表摩擦力或阻力的存在。

其背後的物理方程為二階微分方程： $md^2(x)/dt^2 + cdx/dt + kx = 0$

。目標是：在不告訴 AI 這個微分方程的前提下，給它看一堆帶有雜訊的觀測數據，看它能否自己「學」會這個運動軌跡。

實作方法 (Methodology)

##### 3. 實作方法

我使用 Python 與 PyTorch 建構了一個深度神經網絡 (DNN) 來執行此任務。

數據生成 (Data Generation)：

我模擬了一個理想的阻尼震盪函數  $x(t)=e^{-0.5t}\cos(2\pi t)$

，並在生成的數據中加入了高斯分佈的隨機雜訊 (Gaussian Noise)，以模擬真實世界感測器的誤差。這確保了 AI 必須學習「訊號本身的結構」

而非死背數據點。

模型架構 (Model Architecture)：

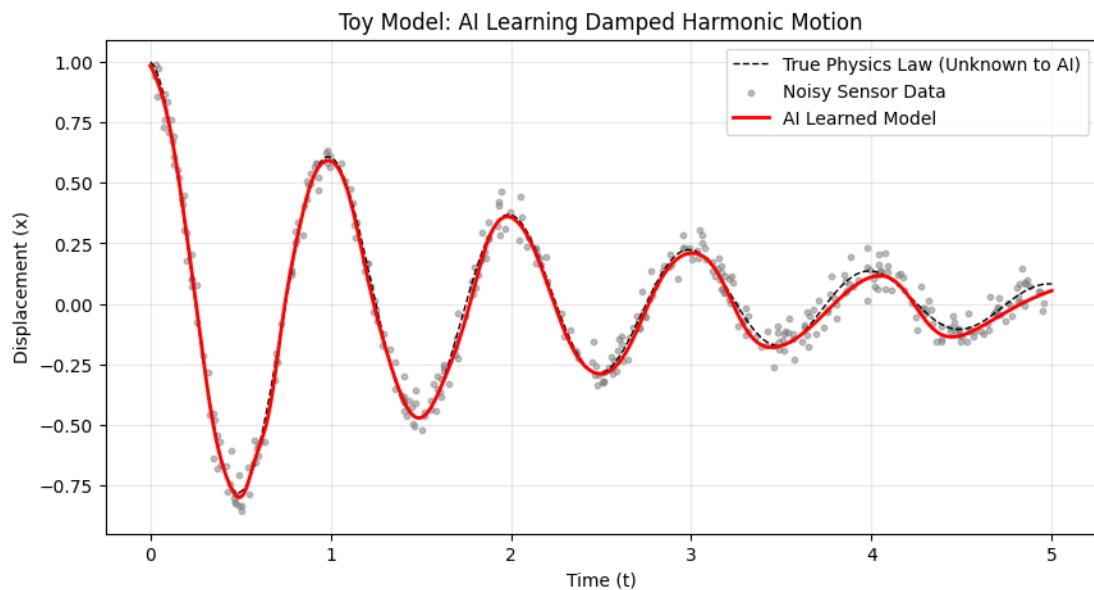
我設計了一個全連接神經網絡 (MLP)。為了捕捉複雜的波形特徵，我選擇了 Tanh (雙曲正切) 作為激活函數，而非一般的 ReLU。因為 Tanh 的輸出範圍在 -1 到 1 之間，且具有平滑的非線性特徵，非常適合處理物理波動訊號。

訓練策略 (Training)：

輸入為時間  $t$ ，輸出為位移  $x$

。使用均方誤差 (MSE Loss) 作為損失函數，透過 Adam 優化器進行 3000 次迭代訓練。

#### 4. 結果



上圖展示了模型的訓練結果。灰色散點代表帶有雜訊的觀測數據，黑色虛線代表真實的物理定律 (AI 未知)，而紅色實線則是 AI 的預測模型。

從圖中可以觀察到幾個關鍵點：

抗噪能力：儘管輸入數據充滿雜訊，AI 依然成功學會了平滑的軌跡，沒有發生過度擬合 (Overfitting) 去追逐每一個雜訊點。

特徵捕捉：AI 精準地抓住了「震盪頻率」以及「指數衰減的包絡線 (Envelope)」。這意味著神經網絡內部已經隱含地構建了類似阻尼震盪的數學邏輯。

#### 5. 結論

這個 Model 成功驗證了「數據驅動物理建模」的可行性。它證明了即使是最簡單的神經網絡，也具備通用函數擬合 (Universal Function Approximation) 的能力來逼近微分方程的解。

這雖然只是一個簡單的彈簧系統，但它確立了 Final Project 的核心邏輯：「觀測數據

→神經網絡 →物理規律」。在接下來的 Final Project 中，我將進一步探討如何將此概念擴展到多變數系統，並引入符號回歸 (Symbolic Regression)，讓 AI 不僅能畫出曲線，還能直接寫出  $F=ma$  這樣的公式，真正實現「AI 科學家」的願景。